

Proyecto 3 Deep Learning

Presentado por **Daniel Cabrera**
Jimmy Martinez
Helen Fonseca



GITHUB: [https://github.com/estdanielscl/deeplearning/blob/main/PROYECTOFINALDL%20\(1\)%20\(1\).ipynb](https://github.com/estdanielscl/deeplearning/blob/main/PROYECTOFINALDL%20(1)%20(1).ipynb)

DATASET: <https://drive.google.com/drive/folders/1lU4DNJGERN9CDTccRerekMUc0JR1gSCB?usp=sharing>

PROPUESTAS EVALUADAS Y SELECCIÓN FINAL

① Toxicidad en Videojuegos

- Detección de lenguaje ofensivo.
- Uso de NLP en chats.
- Problemas:
 - sarcasmo,
 - abreviaciones,
 - ambigüedad.



② Plagio y Parafraseo

- Comparación semántica de textos.
- Uso de embeddings y transformers.
- Problemas:
 - alta complejidad,
 - alto costo computacional.



③ Fake News

- Alta relevancia social.
- Disponibilidad de datasets.
- Uso de modelos modernos.
- Comparación de arquitecturas:
 - Logistic Regression,
 - LSTM,
 - BERT.




DATASETS UTILIZADO

Fake and Real News Dataset

<https://www.kaggle.com/clmentbisailon/fake-and-real-news-dataset>

Archivos:

- Fake.csv

Acerca de este archivo			
noticias falsas			
▲ título	▲ texto	▲ sujeto	📅 fecha
Título del artículo de noticias	Texto principal del artículo de noticias	Tema del artículo periodístico	Fecha de publicación artículo de noticias
17903 valores únicos	[vacío] 3% AP News Los habit... 0% Otro (22851) 97%	Noticias 39% política 29% Otro (7590) 32%	
Donald Trump envía un mensaje vergonzoso en Nochevieja; esto es preocupante.	Donald Trump no podía simplemente desearles a todos los estadounidenses un Feliz Año Nuevo y dejarlo ahí. En cambio, hizo...	Noticias	31 de diciembre de 2017

- True.csv


Acerca de este archivo			
noticias verdaderas			
▲ título	▲ texto	▲ sujeto	📅 fecha
Título del artículo de noticias	Texto principal del artículo de noticias	Tema del artículo periodístico	Fecha de publicación artículo de noticias
20826 valores únicos	21192 valores únicos	Noticias políticas 53% noticias del mundo 47%	
Ante la inminente disputa presupuestaria en Estados Unidos, los republicanos cambian su discurso fiscal	WASHINGTON (Reuters) - El líder de una facción republicana conservadora en el Congreso de Estados Unidos, que votó...	Noticias políticas	31 de diciembre de 2017

Cantidad de datos:

- +44,000 noticias en total.
- Dataset utilizado:
 - 4,000 noticias.


Información incluida:

- Título de la noticia.
- Texto completo.
- Fecha.
- Categoría.
- Etiqueta:
 - Fake (0)
 - True (1)



DIVISIÓN DE DATASETS

Conjunto	Porcentaje	Cantidad Aproximada
Entrenamiento	70%	2800
Validación	15%	600
Prueba	15%	600



PREPROCESAMIENTO DE DATOS

1 Unión de título y contenido



2 Limpieza de texto



3 Eliminación de referencias "Reuters"



4 Eliminación de fuga de datos




5 Tokenización



6 Data augmentation



7 Pruebas de robustez



Ajustes en los datos recibidos

NLTK (Natural Language Toolkit)

Eliminación de columnas innecesarias o datos poco relevantes para el entrenamiento del modelo


- Fecha
- Título
- Tema

Diferenciación de las noticias:

- falsas → 1
- verdaderas → 0

Limpieza del texto del dataset

- Links
- Minúsculas
- Caracteres especiales y signos de puntuación



Tokenización

Divide el texto en unidades mas pequeñas “tokens”

Divide dónde comienza una idea y dónde termina otra




Stopwords

Filtra y elimina las palabras que no aportan significado real a la noticia, este proceso lo realiza al detectar una palabra que se repite muchas veces dentro de varios textos



Lematización

Las palabras restantes se transforman a su forma más simple para hallarlas de una manera más rápida dentro de los textos



Form	Suffix	Stem
studie s	-es	studi
study ing	-ing	study
niñ as	-as	niñ
niñ ez	-ez	niñ

Fuga de datos

limpiar_fuga_reuters

Función encargada de eliminar etiquetas iniciales en las noticias reales, de esta manera el modelo no solo aprenderá a reconocer una palabra para determinar si una noticia es real o no, con esto se vera obligado a realizar un análisis completo de la noticia para determinarlo

title	text	subject	date
As U.S. budget f	WASHINGTON (Reuters) - The head	politicsNews	December 31, 2017
U.S. military to a	WASHINGTON (Reuters) - Transgen	politicsNews	December 29, 2017
Senior U.S. Rep	WASHINGTON (Reuters) - The spec	politicsNews	December 31, 2017
FBI Russia prob	WASHINGTON (Reuters) - Trump ca	politicsNews	December 30, 2017
Trump wants Po	SEATTLE/WASHINGTON (Reuters)	politicsNews	December 29, 2017
White House, Co	WEST PALM BEACH, Fla./WASHING	politicsNews	December 29, 2017

Reales

Falsas

title	text	subject	date
Donald Trump S	Donald Trump just couldn	News	December 31, 2017
Drunk Bragging	House Intelligence Comn	News	December 31, 2017
Sheriff David Cla	On Friday, it was reveale	News	December 30, 2017
Trump Is So Obs	On Christmas day, Donal	News	December 29, 2017
Pope Francis Ju	Pope Francis used his ar	News	December 25, 2017
Racist Alabama	The number of cases of c	News	December 25, 2017






AUMENTO DE DATOS

Data argumentation

Se crean nuevas noticias modificando ligeramente las originales, este proceso se le realiza solamente al conjunto de datos de entrenamiento (X_{train}), el objetivo principal es evitar el sobreajuste

En este caso se reemplazan algunas palabras de una noticia falsa por sinónimos, de esta manera el significado se mantiene (sigue siendo falsa), pero el modelo ve un texto nuevo



Pruebas de robustez

```
def agregar_errores(texto)
```

Su propósito principal es el lograr ser adaptado a publicaciones en redes sociales realizadas por usuarios comunes que cometen errores ortográficos en sus publicaciones

Los modelos lograran identificar noticias falsas en textos que contengan errores de tipeo cambiando letras al azar dentro del texto

```
Accuracy con errores ortográficos:  
0.9983333333333333
```




MODELO BERT

Definicion: es una arquitectura de deep learning basada en transformers, su característica principal es que analiza el texto de forma bidireccional comprendiendo el significado de cada palabra teniendo los dos contextos.


Tokenization: Proceso mediante el cual el texto se divide en pequeñas unidades llamados tokens, después de esto se transforman en embeddings que son vectores numéricos.

- Los embedding ingresan al transformer de bert donde el modelo analiza mediante mecanismos de self attention las relaciones entre todas las palabras del texto simultaneamente
- finalmente la representacion contextual de bert, pasa a una capa densa de clasificacion donde se define si la noticia es verdadera o es falsa.



MODELO BERT


BERT Accuracy: 1.0					
BERT F1-Score: 1.0					
	precision	recall	f1-score	support	
0	1.00	1.00	1.00	333	
1	1.00	1.00	1.00	267	
accuracy			1.00	600	
macro avg	1.00	1.00	1.00	600	
weighted avg	1.00	1.00	1.00	600	



MODELO LSTM


- **Definición:** es un tipo avanzado de Red Neuronal Recurrente (RNN). A diferencia de otras redes neuronales tradicionales que no recuerdan la palabra anterior, LSTM posee memoria. LSTM se rige bajo el parámetro de que debe de olvidar información para poder recordar información adicional. Para lograrlo, usa una estructura interna de gates:
 - Forget Gate: Decide qué información vieja ya no sirve y la olvida (Ej. Si el texto cambia de "él" a "ella", olvida el género masculino)
 - Input Gate: Decide qué información nueva de la oración actual es importante guardar
 - Output Gate: Toma la memoria actual y la palabra que está leyendo y decide qué información enviar a la siguiente palabra

MODELO LSTM



LSTM Accuracy: 0.9583333333333333

LSTM F1-Score: 0.954954954954955



COMPARACION DE MODELOS

El primer modelo fue Naive Bayes, utilizado como baseline tradicional. Este modelo probabilístico se basa en el teorema de Bayes y asume independencia entre las palabras del texto.

- bajo costo computacional,
- rapidez de entrenamiento,
- facilidad de implementación.

El segundo modelo fue LSTM (Long Short-Term Memory), una arquitectura basada en redes neuronales recurrentes.


A diferencia de Naive Bayes, LSTM sí tiene capacidad para procesar secuencias y analizar el orden de las palabras dentro del texto.

Esto le permite:

- capturar dependencias lingüísticas, comprender estructuras gramaticales, y mantener información relevante durante el procesamiento

BERT representa el estado del arte en NLP porque utiliza mecanismos de self-attention que permiten analizar todas las palabras del texto simultáneamente.

A diferencia de LSTM, BERT no procesa el texto secuencialmente palabra por palabra, sino que evalúa las relaciones globales entre todas las palabras al mismo tiempo.



!!Gracias!!

